典型任务测试材料

测试层次

工具/状态、检索、生成、端到端分别记录，不将模拟模型成绩当作真实模型成绩。历史数据基线与当前公开样例版本不同。

经贸标准任务

100 件，每件 FOB 10 美元；整批运费 100 美元、保险 10 美元；人民币汇率 7；关税 10%、增值税 13%，无消费税及国内其他费用。预期计税价格 7770、关税 777、增值税 1111.11、支出合计 9658.11 元，单位支出 96.58 元。规则工具测试达到预期。

经贸变更与比较

汇率 7.2 的假设试算为 9934.06 元；CIF 总价 1080 美元在原汇率 7 下支出 9397.08 元，比原方案低 261.03 元。敏感性试算不自动覆盖原方案，需确认修改语义。

实际结果

经贸专项 41/41 用例通过；核心流程重复 3 次、72/72 断言通过。包含缺参、非法参数、口径比较、状态恢复和导出。使用独立 Decimal 参考计算。真实模型层未执行。

校园基线

115 条用例：105 基础、10 等义改写，静态结构检查通过。历史工具层 11/11 通过。v1.3 检索可测 71 条，文档任一命中 85.92%，文档全命中 78.87%，引文全命中 42.25%。这些不是回答正确率。

问题分析

年度和新老生范围匹配、证据分块完整性仍需优化。生成层、端到端和正式人工签字未完成。ZCode 在经贸报告中使用的“人工复核”应理解为 AI 辅助检查，不作为成员签字证据。

证据位置

trade-demo/evidence、trade-demo/tests、acceptance/cases、acceptance/reports。原报告保留历史版本口径；本次发布说明优先解释其适用范围。